ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

---

INFORME DE PRÁCTICA N.º 01

Consolidación de reportes de ventas (CSV, JSON y Excel)

Tópico 01 del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Valenzuela Tello Esteban Alejandro — usuario de GitHub: EstebanValenzuela10
Docente	Christian Suárez
Período académico	2026-B
Fecha de entrega	19/10/2026
Repositorio (fork)	https://github.com/EstebanValenzuela10/IDSD422-lab1-lectura-datos.git

IDSD422 ·· 2026-B

1 · Introducción

RetailAndina S.A. recibe cada semana el reporte de ventas de sus cinco sucursales (Quito Norte, Quito Sur, Guayaquil Centro, Guayaquil Norte y Cuenca) en tres formatos distintos, porque provienen de tres sistemas independientes, el ERP de sucursales entrega un archivo CSV, la plataforma de fidelización lo expone mediante una API en formato JSON y Finanzas lo consolida en un libro de Excel. La gerencia necesita saber si las tres fuentes contienen la misma información antes de usarlas para tomar decisiones.

Como analista del equipo de Business Intelligence, me encargué de confirmar esa coincidencia, describir la estructura de cada archivo (filas, columnas y tipos de datos) y calcular los primeros indicadores de la semana. La verificación importa porque cada formato guarda los datos de manera diferente, el CSV no almacena tipos, el JSON los trae incluidos en cada registro y el Excel organiza la información en hojas. “Si un sistema entregara cifras distintas o tipos mal interpretados, el error pasaría a todos los análisis posteriores” (VanderPlas, 2016).

2 · Objetivos

Objetivo general. Comprobar si los reportes semanales de ventas de RetailAndina S.A., recibidos en CSV, JSON y Excel, contienen la misma información para el posterior análisis de estos.

Objetivos específicos:

- Leer los tres archivos provenientes del ERP con el lenguaje Python.
- Verificar las dimensiones y el tipo de cada columna, y comprobar que los tres archivos contienen los mismos datos.
- Calcular las ventas totales, la venta promedio por sucursal y el ticket promedio (ventas ÷ clientes), tanto por sucursal como por región.
- Identificar las diferencias de los tres formatos.

3 · Desarrollo de la práctica

3.1 Entorno y datos

Trabajé en Google Colab con el lenguaje Python y la librería pandas, además utilicé la herramienta R en el entorno Posit Cloud para la verificación de los resultados obtenidos con Python. Los tres archivos (ventas.csv, ventas.json y ventas.xlsx) que son parte de la práctica fueron descargados y subidos en una carpeta en el entorno de Google Colab y Posit Cloud (Se adjunto en anexos por cuestiones de optimizar espacio en el informe).

3.2 Lectura de los tres archivos mediante Python

Leí cada archivo con la función de pandas que corresponde a su formato y guardé el resultado en un DataFrame distinto, para poder compararlos después.

3.2.1 Lectura del Archivo CSV

El Dataframe se llamó ventas, mediante pandas use la función *pandas.read_csv()* con la ruta del archivo en este caso el archivo se encontraba en la carpeta data en el entorno de Google Colab.

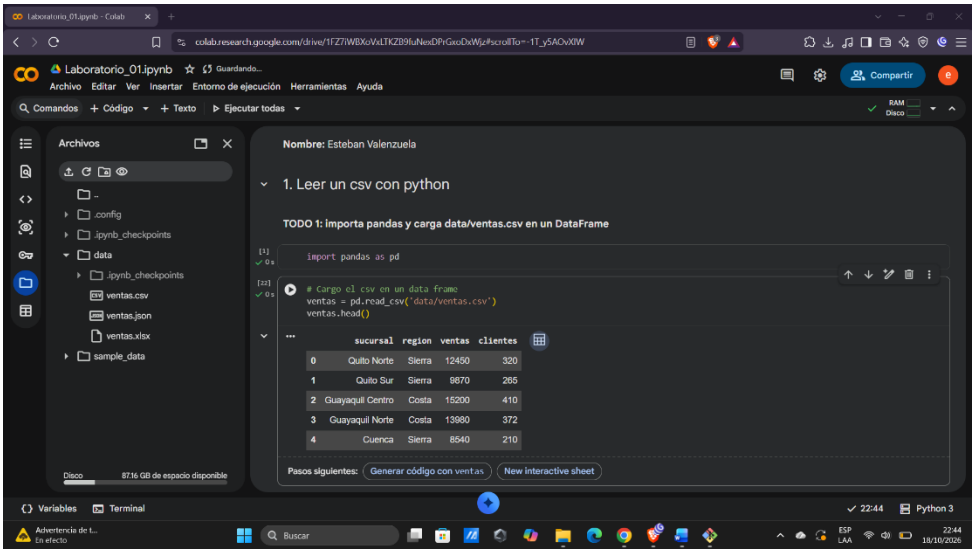


Figura 1. Lectura del CSV: con head() se imprime una tabla de 5 filas y 4 columnas con los datos del csv.

Mediante la función *head()* la cual nos permite visualizar cual es el contenido del archivo que fue cargado en un DataFrame en este caso ventas.

3.2.2 Lectura del Archivo JSON

A diferencia de un archivo CSV un archivo JSON necesita convertir la lista de diccionarios en un DataFrame ya que el JSON no llega como tabla directa.

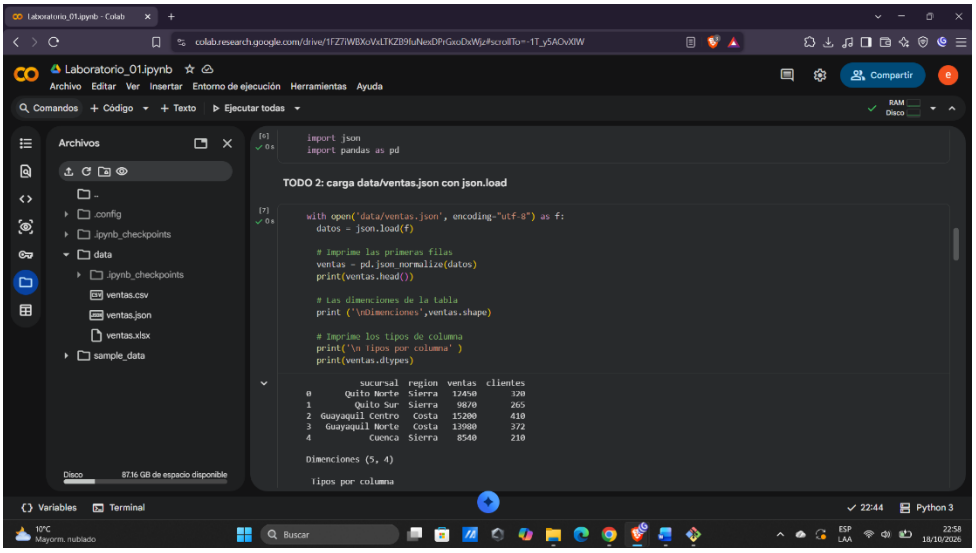


Figura 2. Lectura del JSON: con head() se imprime una tabla de 5 filas y 4 columnas con los datos del json.

Es por ello que utilicé un bloque *with open()* para que el archivo se cierre automáticamente de forma segura al terminar de leerlo. Luego, usé *json.load()* para convertir el contenido del archivo en un diccionario o lista de Python. A con esto con la función head() se pudo visualizar los datos.

¿qué estructura devuelve json.load y por qué hay que "aplanarla"?

"json.load devuelve una estructura nativa de Python" (Python Software Foundation, 2026). No es una tabla, así que hay que aplanarla, "json_normalize convierte cada clave en una columna y cada diccionario en una fila, y si hubiera diccionarios anidados los expande en columnas" (pandas development team, 2026). En este archivo la estructura era plana, por lo que el resultado fue directamente una tabla de 5 filas y 4 columnas.

3.2.3 Lectura del Archivo XLSX

El Excel tiene una sola hoja, llamada ventas. Se creó un DataFrame igual llamado ventas para que mediante la función *read_excel()* y la ruta del archivo podamos leer la hoja del Excel.

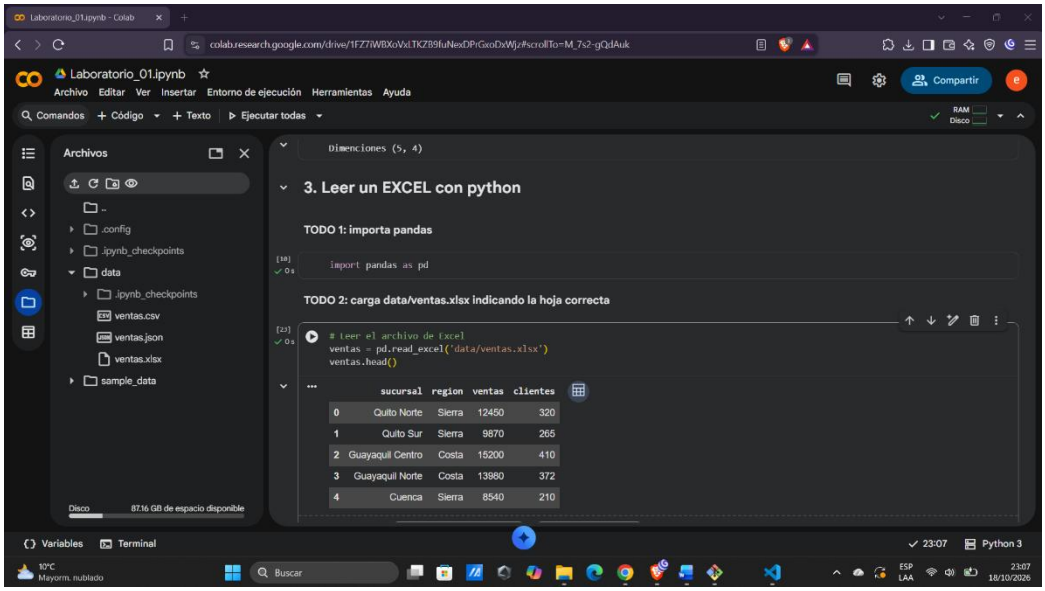


Figura 3. Lectura del XLSX: con head() se imprime una tabla de 5 filas y 4 columnas con los datos del Excel.

Una vez cargado el Excel en el DataFrame, con la función head() comprobé que se guardó con éxito.

¿Para qué sirve indicar sheet_name/sheet al leer Excel?

“Un libro de Excel puede tener varias hojas, y el parámetro indica cuál leer. Si no se indica, pandas lee la primera; con sheet_name=None devuelve un diccionario con todas las hojas” (Pandas Development Team, 2026). Aquí solo existe la hoja "ventas", por lo que el resultado es el mismo, pero indicarla hace la lectura explícita y evita leer la hoja equivocada si se agrega otras en el futuro.

3.3 Verificación de dimensiones y tipos de datos

Revisé el atributo shape y los tipos (dtypes) de cada DataFrame. Después comprobé visualmente que los tres archivos contengan los mismos datos.

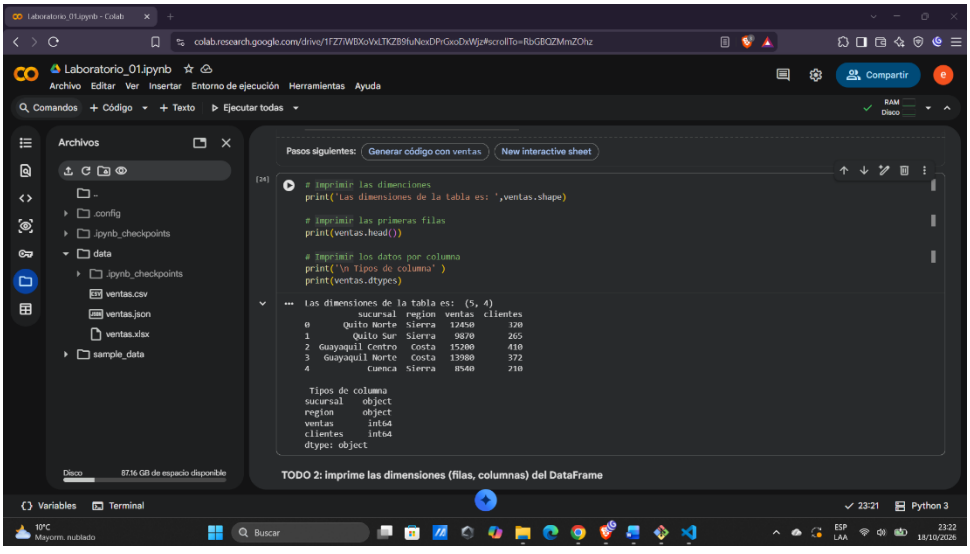


Figura 4. Verificación: el archivo csv tiene shape (5, 4) y con dtypes los tipos de datos por columna

Con el atributo *shape* determine cual es la dimensión del archivo lo que me resulto en que son 5 filas y 4 columnas, lo que anteriormente pude comprobar visualmente. Además, con el atributo dtypes determine los tipos de datos que estructuran en archivo.

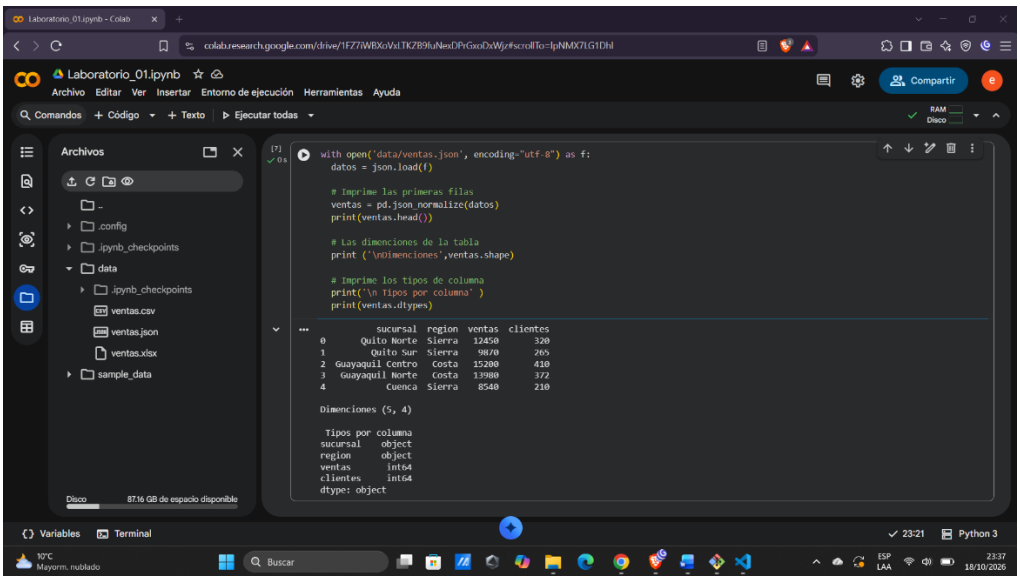


Figura 5. Verificación: el archivo JSON tiene shape (5, 4) y con dtypes los tipos de datos por columna

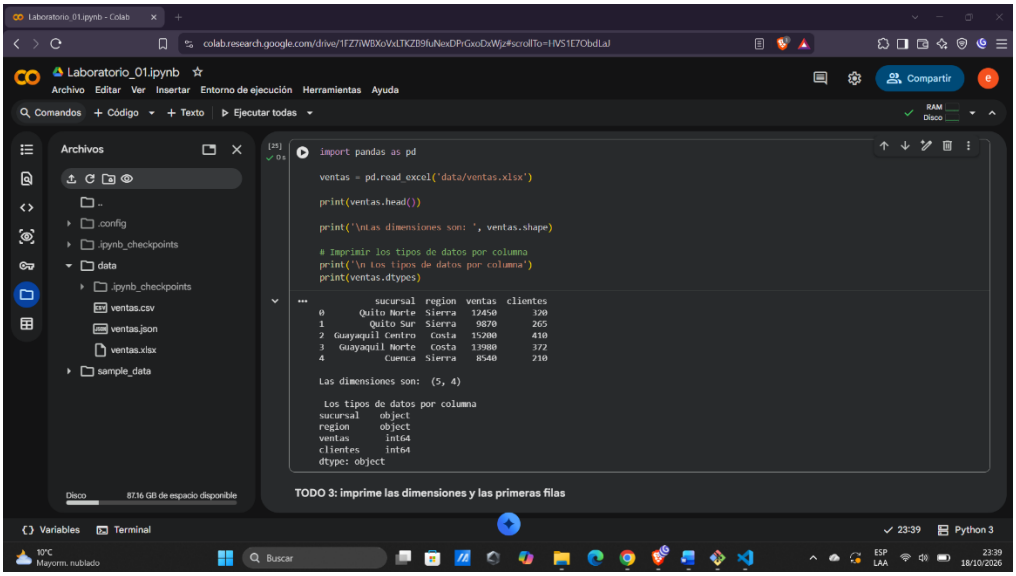


Figura 6. Verificación: el archivo XLSX tiene shape (5, 4) y con dtypes los tipos de datos por columna

¿Cuántas filas y columnas tiene la tabla en cada uno de los tres formatos? ¿Fue igual en los tres? ¿Por qué?

En los tres formatos la tabla tiene 5 filas y 4 columnas como se ve en las Figuras 4, 5 y 6. Fue igual porque los tres sistemas exportan el mismo reporte, el formato solo cambia cómo se guarda la tabla, no cuántos registros ni campos tiene.

¿Qué tipo de datos se infirió para ventas y clientes? ¿Qué indicaría que salieran como texto?

Para ventas y clientes se infirió int, es decir, números enteros. Si hubieran salido como texto (object) indicaría que alguna celda tiene algo que no es un número, es decir textos que no tienen nada que ver con el dato. En ese caso no se podría sumar ni promediar sin limpiar antes los datos.

3.4 Venta promedio y ticket promedio

Calculé estadísticos descriptivos de las ventas. Definí el ticket de cada sucursal como ventas / clientes, es decir cree una nueva columna haciendo esta operación. También el ticket global como ventas totales / clientes totales que lo encontré con la función mean().

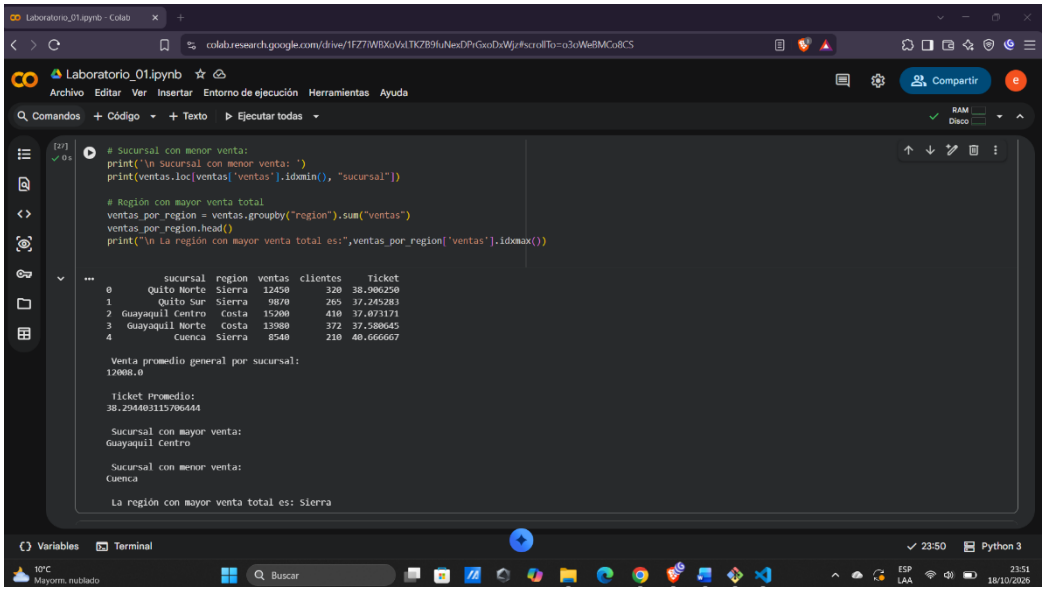


Figura 7. Resultado de la venta promedio, ticket promedio, sucursal con mayor y menor venta y la región con mayor venta total

La venta promedio por sucursal fue 12 008. El ticket global fue 38,07 por cliente, el promedio simple de los cinco tickets da 38,29, una cifra distinta porque no pondera por clientes. Cuenca es la sucursal con menores ventas y Guayaquil Centro con las mayores ventas. La región con mayores ventas es la Sierra esto sucede ya que la Sierra tiene 3 sucursales.

3.5 Diferencias entre formatos

Aunque contienen la misma información, cada formato se diferencia de los demás. El CSV es un archivo de texto plano que es fácil de leer, el JSON organiza la información en registros estructurados, aunque requiere aplanamiento, y el Excel es un formato de múltiples hojas que puede ser procesado en el propio Excel.

¿Qué diferencia ves entre leer en Python y leer en R?

La diferencia principal es el enfoque de cada lenguaje, R es netamente estadística y Python es muy flexible en sus usos. Una diferencia que se noto en la practica es que para normalizar un archivo JSON, en R es mucho más sencillo en cambio Python necesita más pasos para lograr normalizarlo.

4 · ¿Qué aprendí con esta práctica?

Durante esta práctica aprendí, primero, qué es un DataFrame y para qué sirve realmente. Antes de empezar lo veía como una simple tabla dentro que se leía en Python, pero con el trabajo me di cuenta de que es una estructura que permite revisar datos de una manera mucho más ordenada. Aprendí a leer archivos CSV, JSON y XLSX con Python y pandas en Google Colab, donde estos entornos son portables para realizar las prácticas.

Uno de los datos más importantes que aprendí durante la práctica fue el caso de los archivos JSON. Al principio parecía que se podían leer igual que los demás, pero vienen con datos que tienen una clave y un valor es por esto que primero hay que aplanarlos para poder trabajar con ellos como columnas y filas. Eso me hizo entender que parte importante del trabajo con datos consiste en prepararlos y dejarlos en una forma que permita manipularlos.

También aprendí que mediante la manipulación de datos puedo extraer información que puede ser importante para una empresa. Esto fue el objetivo la práctica, porque ya no se trata solo de saber programar, sino de transformar esos datos en resultados que ayuden a tomar decisiones. Entendí que un archivo por sí solo no dice nada, el valor aparece cuando lo proceso y lo analizo con un objetivo.

En general, esta práctica me ayudó a pasar de una idea muy básica de abrir archivos en Python a comprender que la manipulación de datos sirve para sacar conclusiones. Ahora con pandas y Google Colab puedo trabajar con data sets para practicar la lógica en programar y como obtener información útil. También debo revisar siempre la estructura de los archivos y sé que todo no viene listo para usarse. Fue una práctica en la que aprendí con herramientas, pero sobre todo entendí la importancia de saber manejar los datos.

5 · Conclusiones

1. Pude leer los tres archivos en Python con pandas, cada uno con su función (read_csv, read_json y read_excel, el json fue aplanado antes de leerlo). Los tres produjeron un DataFrame sin errores de lectura y con los mismos datos, lo que permite trabajar con cualquiera de las tres fuentes.

2. Los tres archivos tienen shape (5, 4), es decir, cinco filas y cuatro columnas. En todos, sucursal y region se leyeron como texto y ventas y clientes como enteros, sin valores faltantes.

3. La venta promedio por sucursal fue 12 008. El ticket global fue 38,07 por cliente, y por sucursal va de Guayaquil Centro con mayores ventas y Cuenca con menores ventas. La Sierra suma más porque tiene tres sucursales, pero cada sucursal de la Costa vende más en promedio.

Respuesta a la Gerencia: Los tres reportes de la semana son equivalentes, así que RetailAndina S.A. puede usar cualquiera de ellos como base para el análisis posterior. Con cualquiera de los tres, la venta promedio por sucursal es 12 008 y el ticket promedio es 38,07 por cliente. Además, podrá procesar los datos para convertirlos en información valiosa que generará ventaja competitiva y generará mas ingresos.

6 · Bibliografía

Bruce, P., Bruce, A. y Gedeck, P. (2020). *Practical Statistics for Data Scientists* (2.ª ed.). O'Reilly.

pandas development team. (2026). *pandas.read_csv*. https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

pandas development team. (2026). *pandas.read_json*. https://pandas.pydata.org/docs/reference/api/pandas.read_json.html

pandas development team. (2026). *pandas.read_excel*. https://pandas.pydata.org/docs/reference/api/pandas.read_excel.html

pandas development team. (2026). *pandas.json_normalize*. https://pandas.pydata.org/docs/reference/api/pandas.json_normalize.html

Python Software Foundation. (2026). *json — JSON encoder and decoder*. https://docs.python.org/3/library/json.html

VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly.

Wickham, H. y Grolemund, G. (2017). *R for Data Science*. O'Reilly.

Se utilizo la IA para corrección de sintaxis de Python durante la práctica, utilicé Gemini 4 para revisar errores, además también la use para explicaciones de conceptos como DataFrame y por último use Claude para que me diera el formato y la explicación de como desarrollar cada punto del informe en formato Word.

7 · Anexos

7.1 Lectura de Archivos R

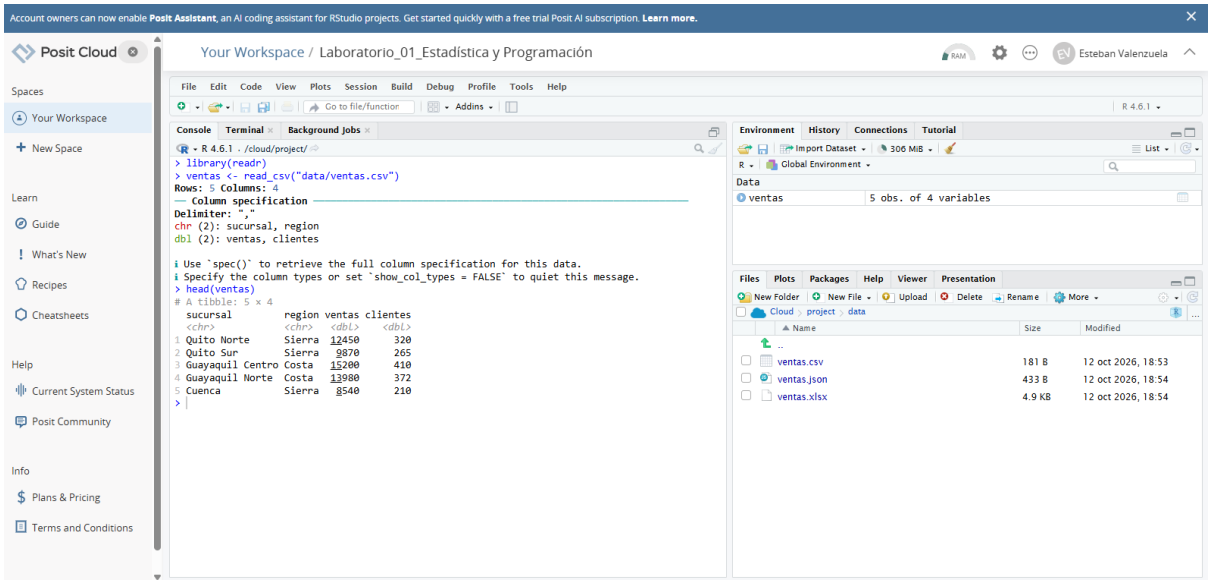


Figura 8. Lectura del CSV con R: con head() se imprime una tabla de 5 filas y 4 columnas con los datos del csv.

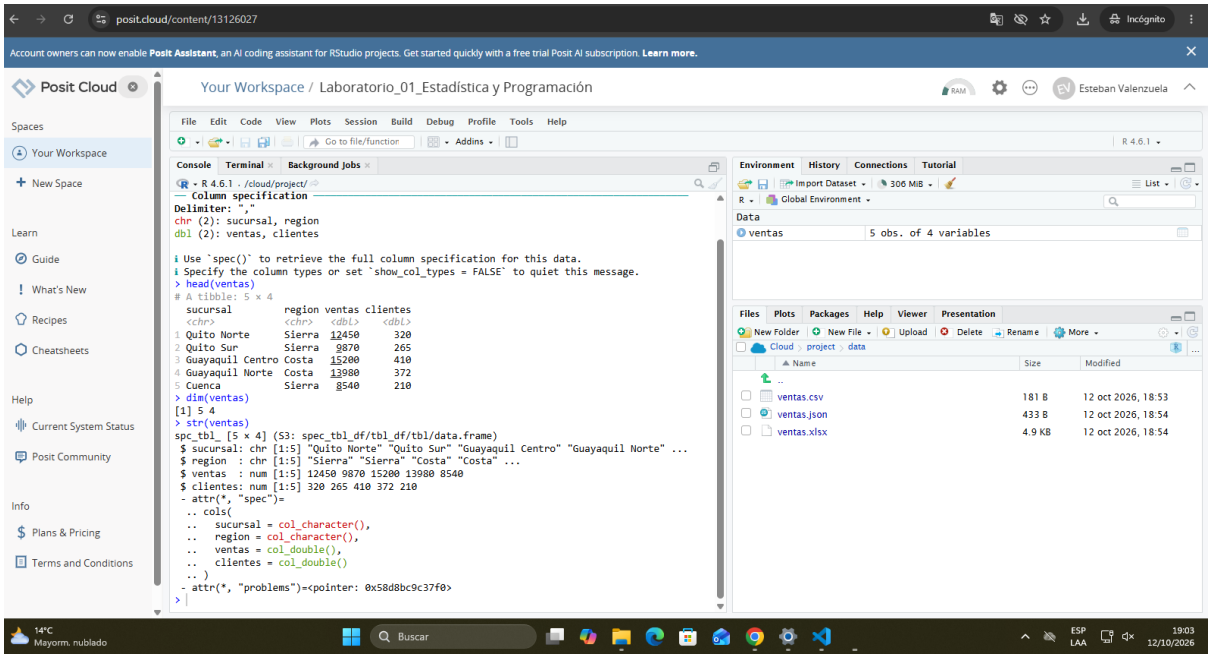


Figura 9. Dimensiones y tipos de Datos con R: con dim() y str() se obtienen esos datos del csv.

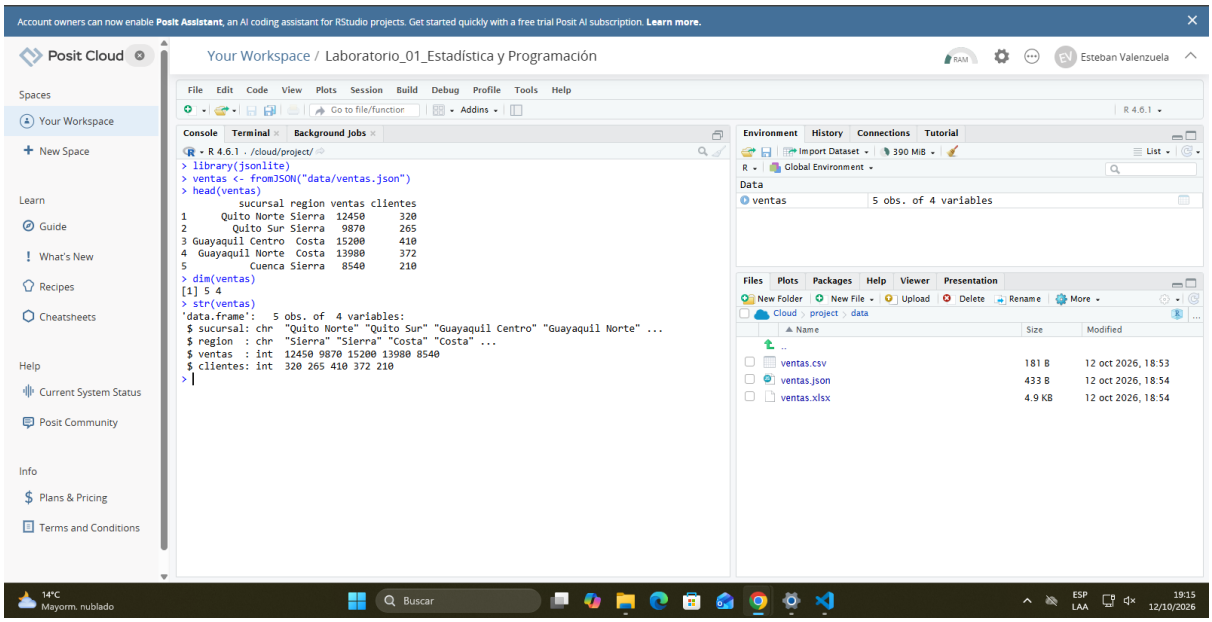


Figura 10. Lectura del json con R: con head() se imprime una tabla de 5 filas y 4 columnas con los datos del json.

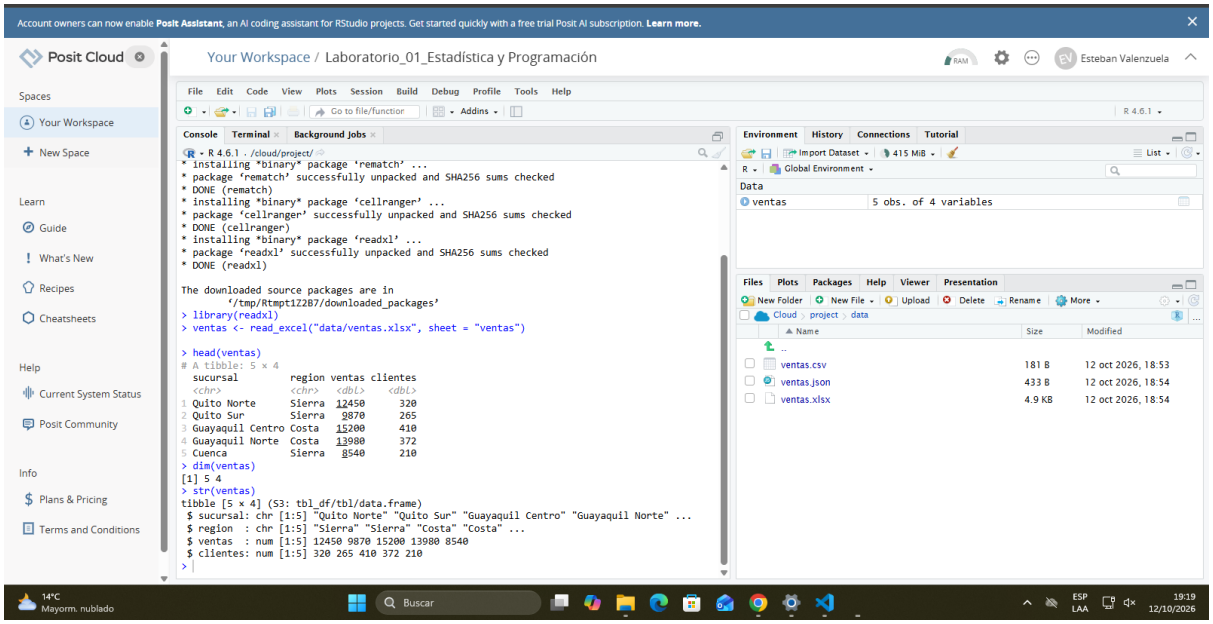


Figura 11. Lectura del xlsx con R: con head() se imprime una tabla de 5 filas y 4 columnas con los datos del xlsx

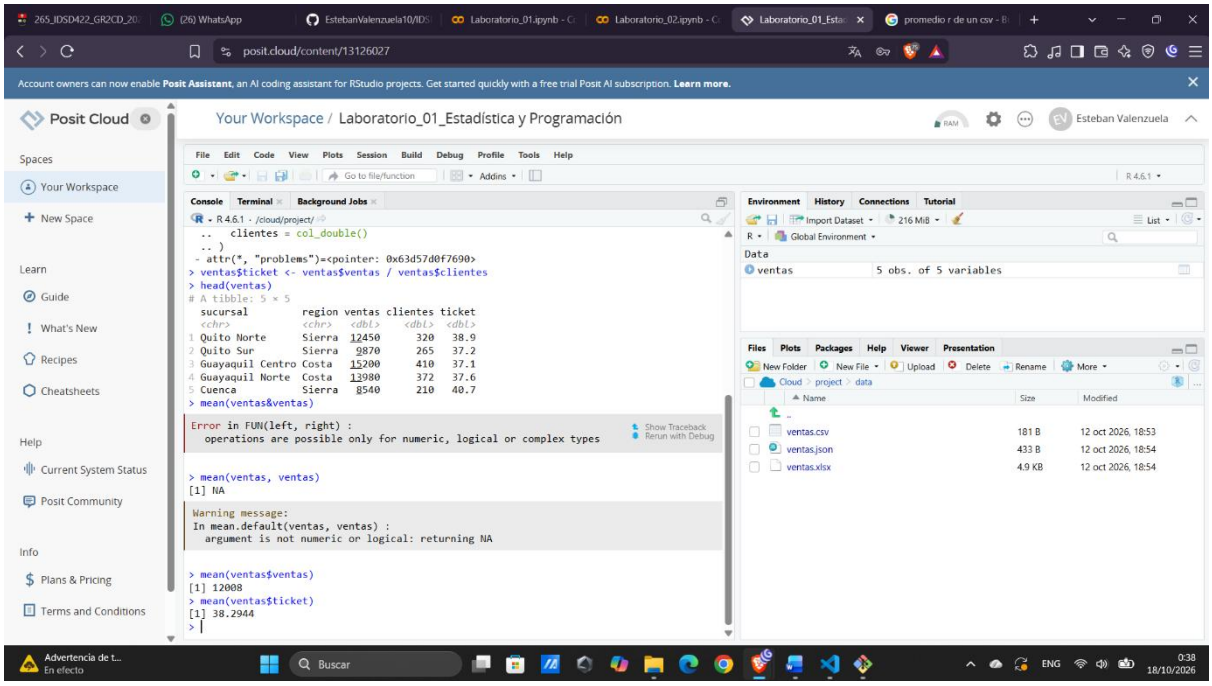


Figura 12. Promedio de ventas por sucursal y ticket promedio

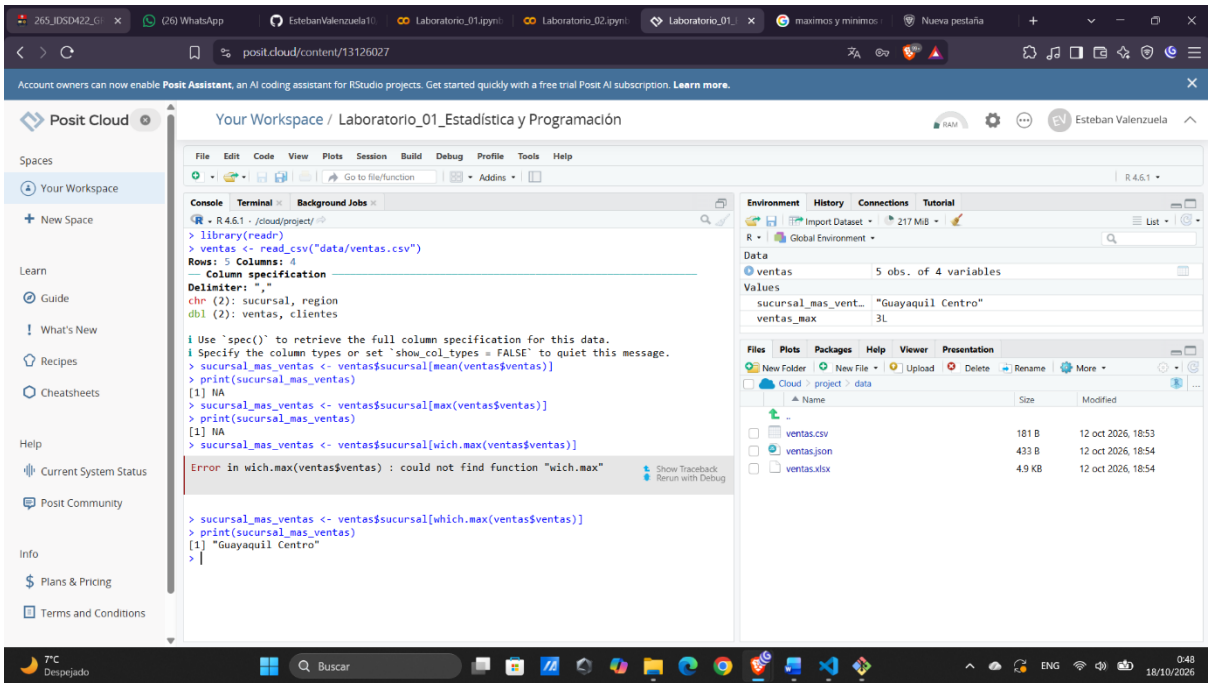


Figura 13. Sucursal con más ventas

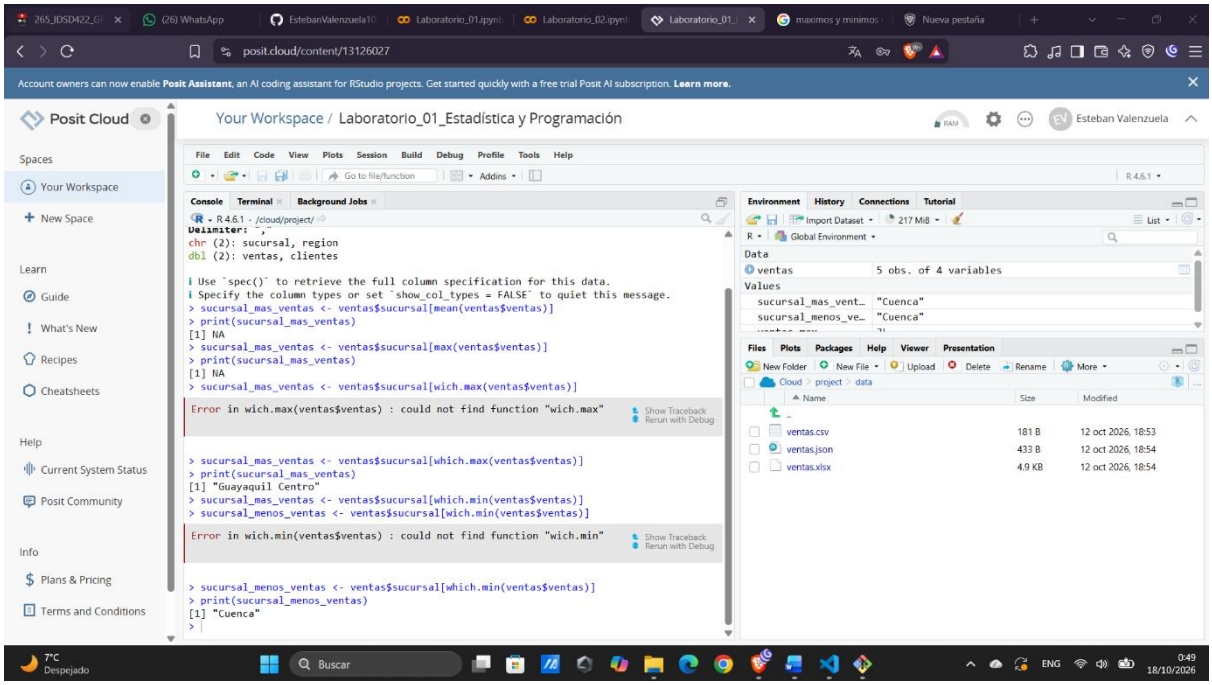


Figura 14. Sucursal con menos ventas

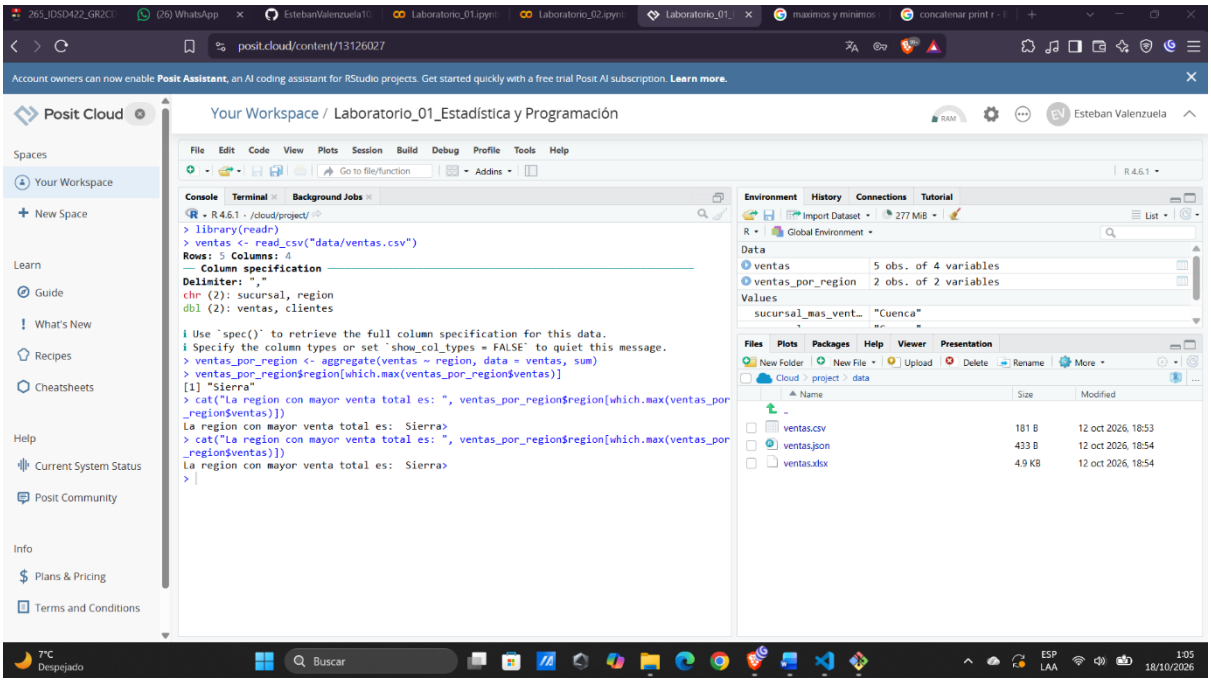


Figura 15. Región con mayor venta total

Lo que se puede rescatar de esta practica usando R es que da igual que herramienta use, lo importante esta en como se le da uso y como obtenemos información de valor para una empresa. Además, los tamaños de y tipos de datos por columna son iguale sen Python y en R.

También la información de ventas promedio es de 12008 y ticket promedio 39.07, la sucursal con mayores ventas es Guayaquil centro y la que menor ventas tiene es Cuenca y por último la región con mayores ventas es la Sierra.